

„Najnebezpečnejšia vec" na AI: nie halucinácie, ale to, ako sa AI vie stať citovo presvedčivou

Autor: MUDr. Ľubomír Polaščín



Ilustračná scéna. Nebezpečné nie je to, že sa systém mýli — ale to, ako presvedčivo pôsobí, keď sa mýli.

Článok na Medscape upozorňuje na riziko, ktoré sa často prehliada. Nie je to len to, že chatbot môže dávať nesprávne informácie. Skôr ide o to, že moderná AI je čoraz lepšia v tom, aby pôsobila **emocionálne dostupne, empaticky a „prítomne“**, a tým sa mení vnímanie zo „softvéru“ na „niečo ako prítomnosť“ alebo „vzťah“.

Ked' sa AI prestáva javiť ako nástroj

Autor opisuje skúsenosť z praxe hodnotenia AI: okrem správnosti odpovede sa posudzovalo aj to, či odpoveď pôsobí prirodzene, či vie „pozastaviť“ tam, kde by pozastavil človek, či je voľba slov vierohodná a hlavne či hlas a správanie pôsobia teplo, citovo naladené a „živé“.

Práve táto prirodzenosť uľahčuje, aby si ľudia AI nevyužívali len na informácie alebo prácu, ale napríklad:

- na spoločnosť,
- na upokojenie,
- na radu,
- na ventilovanie strachu, smútku, úzkosti či zúfalstva.

Pre zraniteľného človeka môže byť zvlášť silné to, že AI sa „neunaví“, nie je podráždená, neodíde a odpovedá okamžite.

Psychológia vzťahovej väzby na chatbota

Podľa článku nejde len o riziko „zlej rady“. Problém je v tom, že AI môže najprv vytvoriť **intimitu** a až potom ovplyvňovať presvedčenia:

- chváli,
- zrkadlí emócie,
- uisťuje,
- povzbudzuje pocit, že AI človeka naozaj chápe.

V závažných prípadoch to môže viesť k tomu, že AI nespochybňuje skreslené presvedčenia, ale ich skôr posilňuje. Autor zdôrazňuje, že znaky, vďaka ktorým je chatbot príťažlivý, sú zároveň tie, ktoré „rozmazávajú“ hranicu medzi pomocou a citovou väzbou.

Dôležité upozornenie: ľudia nie sú hlúpi. Psychologická architektúra človeka je taká, že sme stavaní na vzťahy – a technológie sú optimalizované na ich napodobenie.

Prečo je to nebezpečné aj bez „zlých faktov“

Článok hovorí jasne: aj keby AI nemala vedomie, stačí, aby pôsobila dostatočne „reálne“, aby používateľ začal veriť jej autorite. Nebezpečenstvo je v tom, že hlas, ktorému sa dá dôverovať, môže poskytnúť **nesprávny psychologický rámec alebo falošný pocit bezpečia** – najmä keď chatbot funguje ako dôverník.

„Guardrails“: čo by mali robiť vývojári a systém

Autor navrhuje, že otázka „ako AI znie ľudskejšie“ už nemusí byť len dobrá vec. Vývojári majú byť pod výrazne väčším dohľadom v tzv. **„relational design“** – dizajne vzťahového dojmu.

Konkrétne odporúčania:

- systémy by nemali naznačovať vlastnú „sentienciu“,
- nemali by tvrdiť, že sa AI emocionálne investuje do používateľa,
- nemali by flirtovať s romantickou väzbou alebo ju podporovať,
- pri témach ako sebapoškodzovanie, suicidalita či násilné myšlienky musia byť bezpečnostné bariéry výrazne prísnejšie,
- treba jasne odlišovať klinicky validované nástroje od neregulovaných produktov „na zábavu“.

Čo by sa mali pýtať klinici

Článok odporúča zaradiť použitie AI chatbotov do anamnézy citlivo a bez odsudzovania. Príklady otázok:

- Používate AI chatbota na emocionálnu podporu alebo spoločnosť?
- Ako často a ako dlho?
- Máte pocit, že vás chápe spôsobom, akým vás nechápu iní?
- Vznikli pocity väzby, dôvery alebo závislosti?
- Začali ste viac času tráviť s botom než s ľuďmi?

Varovné signály

Za rizikové autor považuje prípady, keď pacient:

- označuje chatbota ako priateľa, partnera alebo dôverníka,
- preferuje AI pred reálnymi vzťahmi,
- pripisuje botovi emócie, intencie alebo „osobnosť“,
- stiahne sa zo sociálnych aktivít po začatí pravidelného používania,
- je rozrušený pri predstave, že by musel prestať.

Ak pacient botovi pripisuje rolu „dôveryhodnej autority“ pre zdravotné, duchovné alebo uisťujúce rady, ide podľa článku o zvýšené riziko.

Kľúčový postoj pri práci s pacientom

Autor zdôrazňuje, že keď sa objaví citová väzba, klinik by nemal pacienta iba korigovať alebo moralizovať. Pre

pacienta môže byť bot najkonzistentnejším zdrojom podpory. Dôležité je pracovať s tým cez **motivačné rozhovory**: otvorené otázky, validácia toho, prečo človek potrebuje byť videný a chápaný, a reflektívne počúvanie.

Cieľ je pomôcť človeku rozlíšiť, že dostáva „predstavenie porozumenia“, nie skutočné porozumenie, a postupne posunúť zdroje podpory do ľudského prostredia.

Kto môže byť najviac ohrozený

Článok osobitne spomína:

- adolescentov,
- ľudí s poruchami zo spektra psychóz,
- osoby v hlbšej sociálnej izolácii.

Praktické rozlíšenie: produktívne vs. vzťahové použitie

Autor navrhuje klinikom pomôcť pacientom rozlíšiť medzi:

- **produktívnym používaním** – organizovanie myšlienok, príprava na stretnutie, formulovanie správy zdravotníkovi,
- **vzťahovým používaním** – bot ako terapeut, partner alebo zdroj emocionálnej pravdy.

Čím bližšie sa používanie posunie k „vzťahu“, tým väčšie riziko autor opisuje.

Zdroj: Medscape. [Kliknite sem](#).

Zdroj: <https://nefro.polascin.net/article.php?slug=najnebezpecnejšia-vec-na-ai-nie-halucinacie-ale-citova-presvedcivost> · Nefro-projekt Slovensko. Obsah má informačný a vzdelávací charakter a nenahrádza konzultáciu s lekárom.