

Umelá inteligencia v nefrológii: čo už vieme, kde sú limity a kam to smeruje

Autor: MUDr. Ľubomír Polaščín · Publikované: 10.10.2026



Poloschematická vizualizácia. V jadre úloh je algoritmus spoľahlivý; na okrajoch sa istota rozplýva – a tam začína zodpovednosť lekára.

Úvod: prečo je nefrológia pre AI prirodzené pole

Umelá inteligencia (AI) sa v medicíne rozširuje naprieč odborními, no nefrológia podľa dostupných prehľadov doteraz zaostávala v zavádzaní a praktickom využití. Pritom je pre AI prirodzeným poľom: pracuje s veľkým množstvom štruktúrovaných dát, ktoré sú zároveň matematicky „čitateľné“. Navyše v klinickej praxi ide často o rozhodovanie v časovom tlaku (napríklad skoré zachytenie AKI) a o riziká s jasnými parametrami (progresia CKD, komplikácie, dialyzačné udalosti).

AI v zdravotníctve nemá nefrológa nahradiť, ale rozšíriť jeho možnosti: spracovať viac dát, rýchlejšie identifikovať riziká a pomôcť pri tvorbe presnejších a včasnejších postupov.

Základné pojmy: AI, ML a deep learning (a prečo na tom záleží)

Pre kliniku je užitočné vedieť, že AI je zastrešujúci pojem a jej najčastejšie používanou zložkou v medicíne je strojové učenie (machine learning, ML).

ML sa dá zjednodušene deliť na:

- **učenie s učiteľom** (supervised learning, učenie s označenými výsledkami): model sa trénuje na dátach, kde vopred vieme, čo je „správny“ výstup,
- **učenie bez učiteľa** (unsupervised learning, učenie bez označení): hľadá vzťahy a vzorce v dátach bez vopred nastavenej úlohy,
- **učenie posilňovaním** (reinforcement learning): model sa „učí“ cez odmeny a penalizácie, čo v medicíne naráža na etické limity (experimentovanie v reálnom čase zvyčajne nie je možné, preto sa pracuje skôr s retrospektívnymi dátami).

Od tradičných štatistických skórovacích systémov sa ML líši tým, že dokáže flexibilne prispôbiť váhy jednotlivých premenných a generovať výstupy bez priameho ľudského zásahu v kroku rozhodovania.

Kľúčový koncept klinickej rozhodovacej podpory: životný cyklus AI

AI určená na klinické rozhodovanie typicky prechádza cyklom: tréning na dátach, validácia, nasadenie do klinického procesu a priebežné hodnotenie. Reálny výkon pritom neurčuje len „presnosť“ na testovacej vzorke, ale aj to, ako model reaguje na zmeny populácie, praxe alebo zberu dát.

Kde má AI v nefrológii najväčší potenciál

1) Akútne poškodenie obličiek (AKI): skoré zachytenie a predikcia

AKI je heterogénny syndróm s rôznymi mechanizmami, ktoré sa nakoniec môžu „zlievať“ do spoločného klinického výsledku (napríklad zvýšenie kreatinínu a/alebo zníženie diurézy). Práve táto rôznorodosť robí skoré predikcie náročnými.

AI a ML sa využívajú na:

- **predikciu AKI** (napr. v pooperačnom období),
- **podporu klinického rozhodovania** (clinical decision support),
- **analýzu fenotypov** pomocou prístupov bez učiteľa, napríklad pri AKI spojenom so sepsou.

Konkrétne príklady zo zdroja:

- v retrospektívnej analýze **2 010 pacientov** po cievnych a hrudných výkonoch (vrátane srdcovej chirurgie) na predikciu pooperačného AKI vyšlo, že **extreme gradient boosting** prekonal tradičné modely,
- v rozsiahlej dátovej práci s **703 782 pacientmi** model predikoval AKI s vysokou schopnosťou zachytiť prípady, ktoré následne vyžadovali dialýzu, pričom upozornenie mohlo prísť **až 48 hodín pred dialýzou**. Zároveň sa uvádza aj problém s vyššou mierou falošne pozitívnych predikcií a otázka prenositeľnosti výsledkov (model bol trénovaný na populácii s prevahou mužov),
- štúdie klinickej rozhodovacej podpory ukazujú zmiešané výsledky: niektoré pozorovali skrátenie hospitalizácie a mierny pokles mortality, no v randomizovanej štúdii so **6 030 pacientmi** nebol pri AKI preukázaný prínos push notifikácií/alertov v EHR ani pre dĺžku hospitalizácie, ani pre mortalitu.

Praktický význam: AI môže pomôcť identifikovať nielen samotné AKI, ale aj pacientov s vyšším rizikom, aby sa spustil včasný intervenčný plán. Dôraz sa kladie aj na možnosti **NLP** (spracovanie textu v klinických poznámkach), ktoré dokážu vyťažiť informácie z dokumentácie nad rámec izolovaných laboratórnych hodnôt.

2) Chronická choroba obličiek (CKD): skoré rozpoznanie a odhad progresie

CKD ostáva v praxi poddiagnostikovaná a podhlásená, čiastočne aj pre nedostatok nákladovo efektívnych skriningových postupov a pre variabilitu v odosielaní na nefrológiu (odlišné prahy a vzory podľa GFR).

AI môže pomôcť najmä pri:

- **detekcii CKD v raných fázach**,
- **odhade rizika progresie** (napríklad pri diabetickej chorobe obličiek),
- **predikcii komplikácií** u diabetikov.

Zo zdroja:

- model založený na logistickej regresii predpovedal progresiu diabetickej nefropatie s približne **71 % presnosťou** s využitím albuminúrie a biomarkerov (vrátane napr. močových L-type fatty acid-binding proteínov a sérového TNF- α),
- prístupy typu random forest sa používajú aj na detekciu retinopatie, neuropatie a nefropatie s uvádzanou presnosťou okolo **0,838**,

- spomína sa aj skrining vysokého rizika **Fabryho choroby** pomocou kombinácie fenotypových signálov a klinických charakteristík,
- uvádza sa viac modelov pre progresiu CKD vrátane systému s patentovaným prístupom (pulzové dáta) s uvádzanými C-štatistikami v horizontoch 1, 2 a 5 rokov (približne 0,84, 0,81 a 0,79),
- jeden komerčný model spomínaný v texte (KidneyIntelX) využíva plazmatické biomarkery, širokú paletu laboratórnych hodnôt, diagnózy, lieky a vitálne funkcie merané v troch časových bodoch; výkon sa udáva ako **C-štatistika ~0,77** a zdroj opisuje aj integráciu do EHR v rámci konkrétneho systému (Mount Sinai) a následnú ekonomickú analýzu s hypotézou úspory nákladov z menšieho počtu neplánovaných začatí dialýzy („crash starts“) a z pomalšej progresie DKD.

Pre klinika z toho vyplýva, že AI môže podporiť včasné odoslanie na nefrológiu a cielenejšie rozvrstvenie rizika, čo zodpovedá posunu k „value-based care“.

3) Dialýza: predikcia udalostí a podpora výkonu

Dialýza je v časti krajín vysoko štandardizovaná, najmä v dialyzačných centrách. Vzniká tak veľa dát vhodných pre ML: predpisy (čas liečby, ultrafiltrácia, prietok dialyzátu), lieky podané počas dialýzy a ďalšie parametre v digitálnej forme.

Najčastejšie smerovania AI v dialýze podľa textu:

- **NLP nad EHR**: identifikácia príznakov (napr. únava, bolesť, nauzea alebo vracanie) a porovnanie výstupu s kódovaním podľa klasifikácií,
- **predikcia intradialyzačnej hypotenzie** pomocou rekurentných neurónových sietí a modelov, ktoré sa porovnávajú s logistickou regresiou a boosting prístupmi,
- **predikcia hospitalizácie** u ambulantných hemodialyzovaných pacientov s následnou intervenciou interdisciplinárnym tímom,
- **odhad mortality** napríklad cez Coxov model so súborom klinických parametrov (vek, kreatinín, draslík, hemoglobín, albumín, diabetes, Kt/V a ďalšie).

Hoci dialýza prináša vhodné dáta, AI sa v nej zatiaľ široko rutinne nepoužíva (s výnimkami, napríklad v oblasti anémie). Zdroj ako dôvody uvádza reguláciu, ochranu súkromia a náročnosť integrácie do každodennej práce.

4) Transplantácia obličky: alokácia, párovanie darcu a príjemcu, patológia

Transplantácia je mnohorozmerná oblasť a AI sa v texte spomína pri:

- alokácii orgánov,
- imunosupresívnej liečbe,
- zobrazovaní a hodnotení patológie štepu,
- párovaní darcu a príjemcu (donor-recipient matching).

Konkrétne príklady z článku:

- existuje predikčný systém „iBox“ na odhad dlhodobého rizika zlyhania štepu, ktorý v uvedenom porovnaní predpovedal lepšie než nefrológovia a bol tiež externe validovaný v štúdiách v USA a Európe,
- pri alokácii a spravodlivosti zdroj spomína koncepty a rámce, ktoré sa snažia riešiť nerovnosti v prístupe k transplantáciám. Ako príklad sa uvádza aj kontinuálne bodové priradovanie pri alokácii pľúc, ktoré môže poslúžiť ako vzor pre iné orgány,
- párovanie darcu a príjemcu: uvádza sa online nástroj na rozhodovanie o prijatí alebo odmietnutí „marginálnych“ ponúk na základe očakávaného posttransplantačného prežívania a Kidney Donor Profile Indexu,
- okrem obličiek sa v texte spomína aj použitie modelov prežívania v kontexte transplantácie pečene u diabetikov a vplyv diabetu na mortalitu.

5) Zobrazovanie a patológia: automatizácia „tvrdej“ diagnostiky

V texte sa spomína aj AI v oblasti:

- automatického hodnotenia glomerulárnych lézií pri lupusovej nefritíde cez hlboké konvolučné neurónové siete (CNN),
- klasifikácie ochorení cez viacúlohové prístupy (multitask učenie s CNN),
- rozlišovania benígnych a malígnych lézií na rutinnom MR zobrazení cez architektúry typu ResNet v ensemble prístupe,
- segmentácie objemov pri ADPKD pomocou algoritmov, ktoré sa porovnávajú s medzipozorovateľskou variabilitou.

Klinický význam spočíva v tom, že ide o oblasti s vysokým podielom subjektívnej interpretácie. AI môže pomôcť hodnotenie zjednotiť, ak je validované a nasadené bezpečným spôsobom.

Najväčšie prekážky implementácie AI v medicíne

Bias a nerovnosti v dátach

AI môže preberať skreslenia už na úrovni zberu a spracovania dát. Zdroj explicitne uvádza príklady ako rozdiely v praxi pri výpočtoch GFR s rasovými úpravami a možný dopad na včasné zachytenie a starostlivosť u černošských pacientov.

Kvalita dát: heterogenita, chýbajúce údaje, rozdiely medzi EHR platformami

V medicínskych dátach často chýbajú podstatné hodnoty, údaje bývajú neštandardizované a rozptýlené naprieč dokumentáciou a EHR systémami. Výsledkom môže byť slabšia generalizácia a zhoršené fungovanie modelu v skupinách, ktoré boli podreprezentované.

Zdroj spomína aj praktický smer: integráciu AI do EHR tak, aby sa dáta zbierali konzistentnejšie v reálnom čase a spracovali sa ešte pred vstupom do modelu.

„Black box“ a transparentnosť

Ak model nevysvetlí, ako dospel k rozhodnutiu, vzniká problém dôvery. V medicíne to nie je len akademická nevýhoda. Keď ide o rozhodovanie o rizikách či liečbe, transparentnosť je kľúčová.

Bezpečnosť: zmeny v realite menia distribúciu

Model trénovaný na jednej „distribúcii“ dát môže zlyhávať vtedy, keď sa zmenia podmienky v praxi (distribution shift). Zdroj uvádza, že sa to dá čiastočne zmierniť tréňovaním na viacerých distribúciách a naučením modelu, ako reagovať v situáciách mimo tréningového rozsahu.

Zodpovednosť a etika

V texte sa spomína regulácia v USA cez rámce pre AI ako softvér v role medicínskeho zariadenia (v odkaze na FDA) a zároveň etické otázky: kto nesie zodpovednosť za škodu, transparentnosť, férovosť algoritmu a súkromie dát. Otvára sa aj téma, že AI môže vstupovať do rozhodnutí mimo kliniky, napríklad pri schvaľovaní liečby poisťovňami, čo môže komplikovať nezávislé klinické rozhodovanie a účasť pacienta.

Budúcnosť ML v nefrológii: tréning, validácia a dôkazy z reálnej praxe

Zdroj zdôrazňuje, že AI je v nefrológii stále nedostatočne využívaná a potrebuje viac validácií. Zároveň si všíma význam vzdelávania: väčšina tréningu klinikov v EHR pokrýva základné zaznamenávanie, nie porozumenie životnému cyklu dát (čo sa zbiera, ako sa to normalizuje, čo model „vidí“).

Pri posune k value-based care môže AI znásobiť kapacitu tímu: ušetriť čas pri dokumentácii, znížiť administratívnu záťaž a umožniť viac času na priamu starostlivosť.

V oblasti klinických štúdií sa spomína využitie ML na získavanie dôkazov z dát z bežnej praxe (real-world data), prípadne syntetické kontrolné ramená a zrýchlenie procesov cez automatizované vyhodnocovanie obrázkov a skenov.

Záver

AI má potenciál výrazne zmeniť nefrologickú starostlivosť: skoré odhalenie AKI, presnejší odhad progresie CKD, podporu dialyzačných rozhodnutí, pomoc v transplantácii a automatizáciu časti diagnostiky v patológii a zobrazovaní. Zároveň však platí, že integrácia do klinickej praxe nie je len otázkou „či to funguje“. Musia byť vyriešené bezpečnosť, férovosť, transparentnosť, zodpovednosť a ochrana súkromia. Najväčšiu praktickú výhodu budú mať tí, ktorí dokážu AI rozumne používať tak, aby zvyšovala kvalitu práce nefrológa, nie aby nahrádzala klinický úsudok.

Zdroj: Prehľadový (recenzný) článok na PMC. [Link na zdroj](#).

Zdroj: <https://nefro.polasci.net/article.php?slug=umela-inteligencia-nefrologia-co-vieme-limity> · Nefro-projekt Slovensko. Obsah má informačný a vzdelávací charakter a nenahrádza konzultáciu s lekárom.